Разведочный анализ данных

1) Текстовое описание набора данных

В качестве набора данных будем использовать датасет в котором содержится информация о ценах пиццы в различных популярных пиццериях. Файл pizza_data.csv содержит следующие колонки:

- Company - Название компании
- Pizza Name - Название пиццы
- Type - Тип пиццы
- Size - Размер пиццы в дюймах
- Price - Цена пиццы в долларах

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

Загрузка данных

In [2]:
```
df = pd.read_csv("pizza_data.csv")
```

2) Основные характеристики датасета

In [4]:
```
#Отобразим первые 5 строк датасета:
df.head()
```

Out[4]:

	Company	Pizza Name	Type	Size	Price
0	Domino's Pizza	Hand Tossed	Cheeses Pizza	Small (10")	$5.99
1	Domino's Pizza	Hand Tossed	Cheeses Pizza	Medium (12")	$7.99
2	Domino's Pizza	Hand Tossed	Cheeses Pizza	Large (14")	$9.99
3	Domino's Pizza	Handmade Pan	Cheeses Pizza	Medium (12")	$7.99
4	Domino's Pizza	Crunchy Thin Crust	Cheeses Pizza	Small (10")	$5.99

In [5]:
```
#Определим размер датасета
size = df.shape
print("Всего строк: {}".format(size[0]))
print("Всего столбцов: {}".format(size[1]))
```

```
Всего строк: 371
Всего столбцов: 5
```

In [6]:
```

```

```
#Список колонок с типами данных
df.dtypes
```

Out[6]:
```
Company       object
Pizza Name    object
Type          object
Size          object
Price         object
dtype: object
```

Преобразуем столбцы "Price" и "Size" в тип float и int соответственно:

In [7]:
```
for i in range(df.shape[0]):
    df["Price"][i] = float(df["Price"][i][1:])
    if "Small" in df["Size"][i]:
        df["Size"][i] = 10
    elif "Medium" in df["Size"][i]:
        df["Size"][i] = 12
    elif "Large" in df["Size"][i]:
        df["Size"][i] = 14
    elif "X-Large" in df["Size"][i]:
        df["Size"][i] = 16
    elif "Personal" in df["Size"][i]:
        df["Size"][i] = 7
    elif "Mini" in df["Size"][i]:
        df["Size"][i] = 8
    elif "Jumbo" in df["Size"][i]:
        df["Size"][i] = 18
df["Size"] = df["Size"].astype("int")
df["Price"] = df["Price"].astype("float")
```

In [8]:
```
#Проверим результат
df.dtypes
```

Out[8]:
```
Company       object
Pizza Name    object
Type          object
Size           int32
Price        float64
dtype: object
```

In [9]:
```
#Проверка на наличие пустых значений
for col in df.columns:
    temp = df[df[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp))
```

```
Company - 0
Pizza Name - 0
Type - 0
Size - 0
Price - 0
```

In [10]:
```
#Найдём основные статичтические характеристики набора данных
df.describe()
```

Out[10]:

	Size	Price
count	371.000000	371.000000
mean	12.506739	16.319326

std	2.290246	5.714662
min	7.000000	4.290000
25%	12.000000	12.490000
50%	12.000000	15.490000
75%	14.000000	19.950000
max	18.000000	29.990000

3) Визуальное исследование датасета

Диаграмма расеяния

In [11]:
```
fig, ax = plt.subplots(figsize=(8,8))
sns.scatterplot(ax=ax, x='Size', y='Price', data=df)
```

Out[11]:
```
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

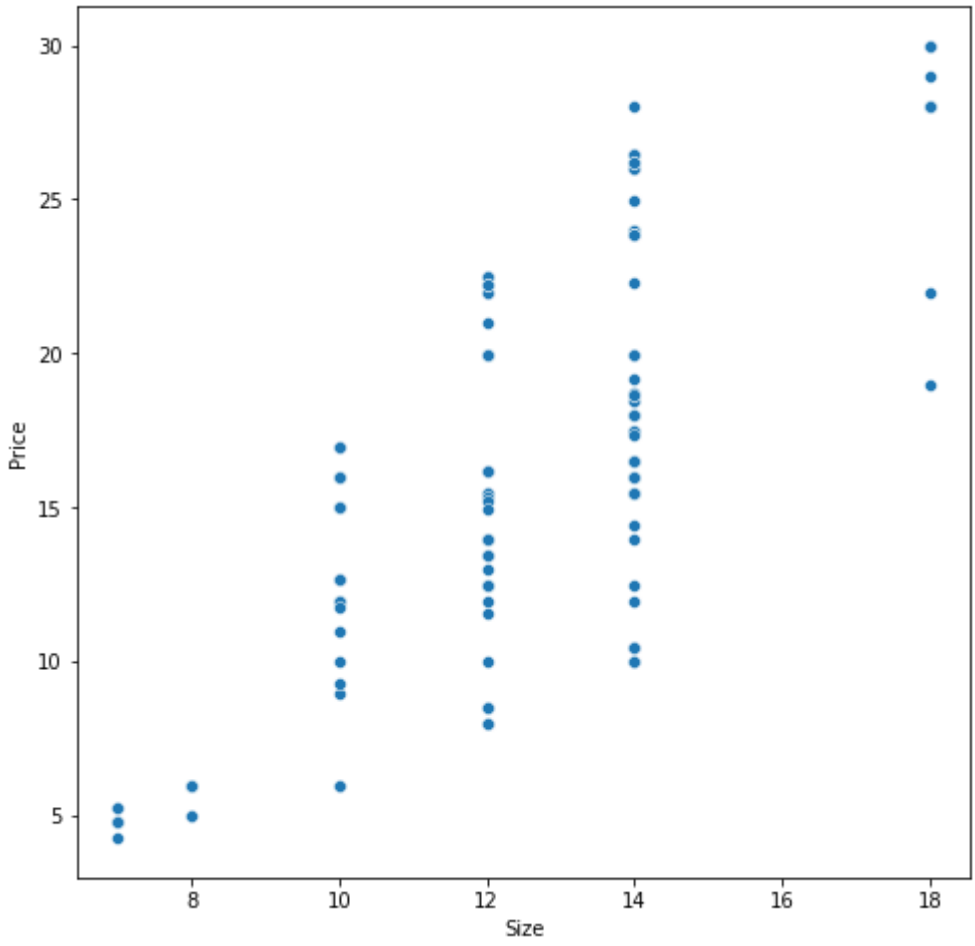

In [12]:
```
#Зависимость цены и размера от типа пиццы
fig, ax = plt.subplots(figsize=(8,8))
sns.scatterplot(ax=ax, x='Size', y='Price', data=df, hue="Type")
```

Out[12]:
```
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

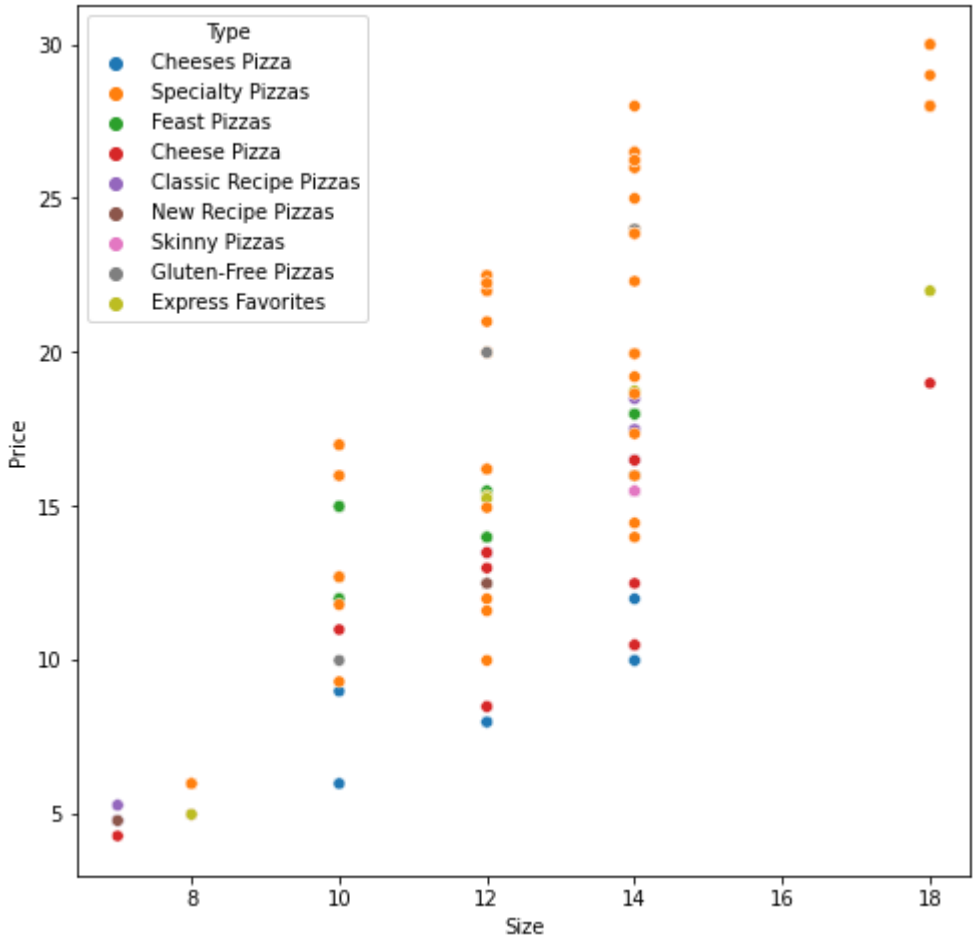

Гистограмма

In [13]:
```
#Оценим распределение цены с помощью гистограммы
fig, ax = plt.subplots(figsize=(8,8))
sns.distplot(df["Price"])
```

```
c:\users\иван\appdata\local\programs\python\python37\lib\site-packages\se
aborn\distributions.py:2619: FutureWarning: `distplot` is a deprecated fu
nction and will be removed in a future version. Please adapt your code to
use either `displot` (a figure-level function with similar flexibility) o
r `histplot` (an axes-level function for histograms).
  warnings.warn(msg, FutureWarning)
```

Out[13]:
```
<AxesSubplot:xlabel='Price', ylabel='Density'>
```

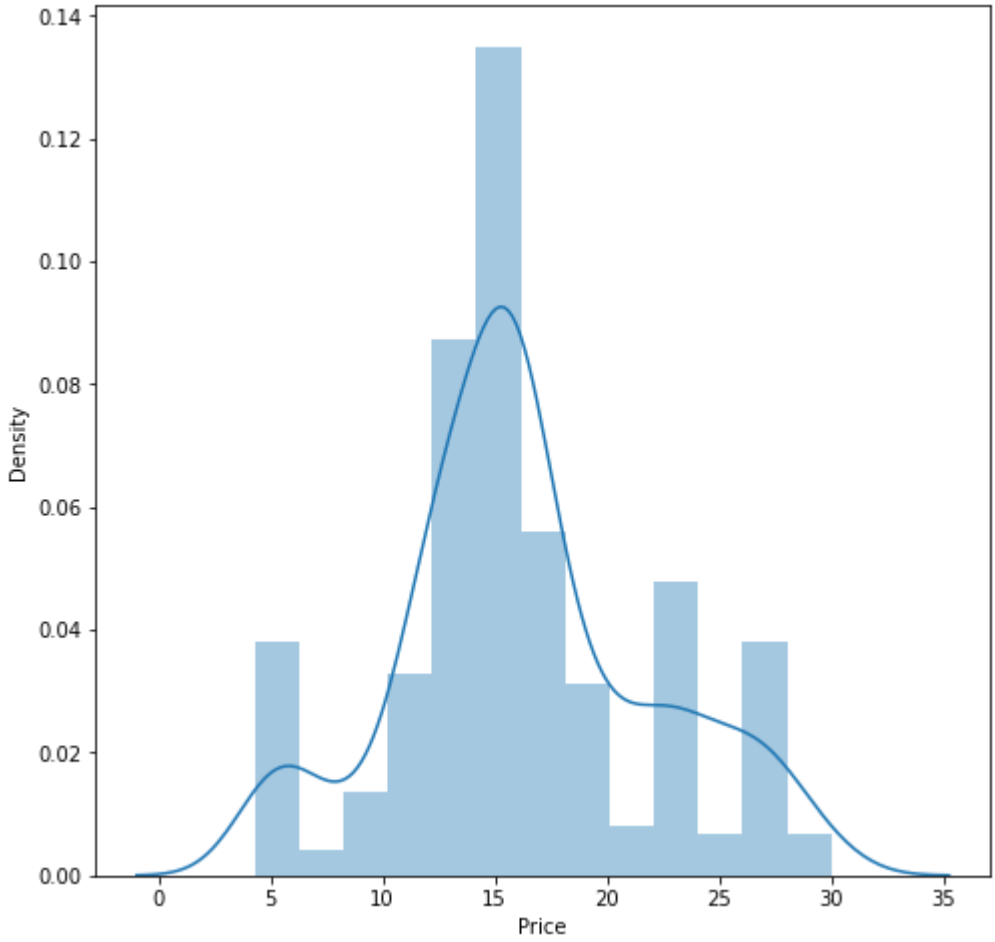

In [14]:
```
#Комбинация гистограмм и диаграмм рассеивания
sns.jointplot(x='Size', y='Price', data=df)
```

Out[14]:
```
<seaborn.axisgrid.JointGrid at 0x1ddd67db188>
```

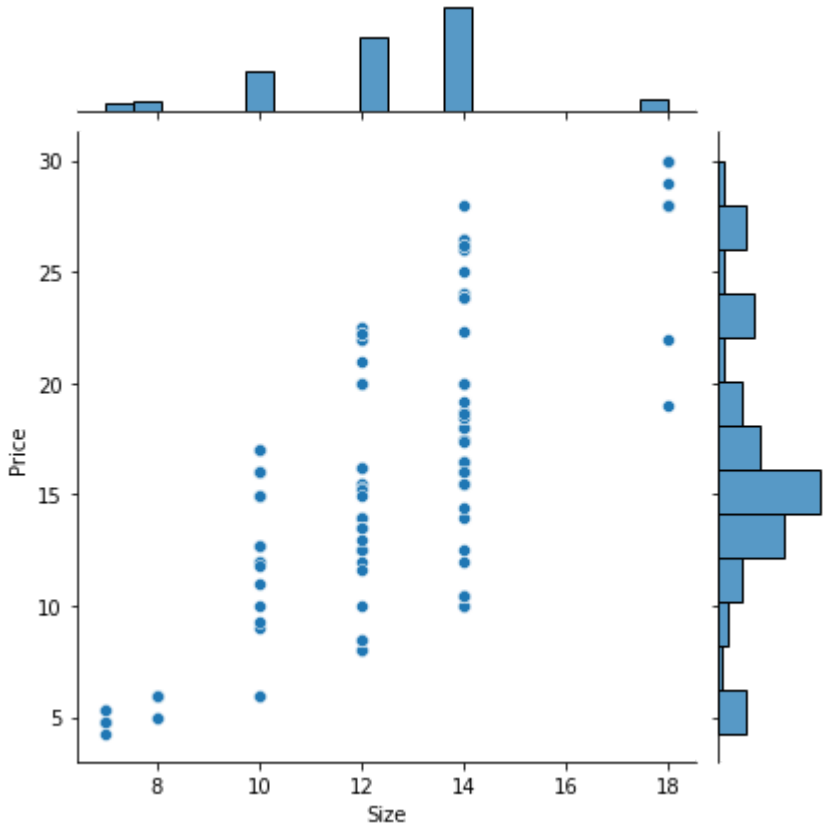

In [15]:
```
sns.jointplot(x='Size', y='Price', data=df, kind="hex")
```

Out[15]:
```
<seaborn.axisgrid.JointGrid at 0x1ddd8fc8cc8>
```

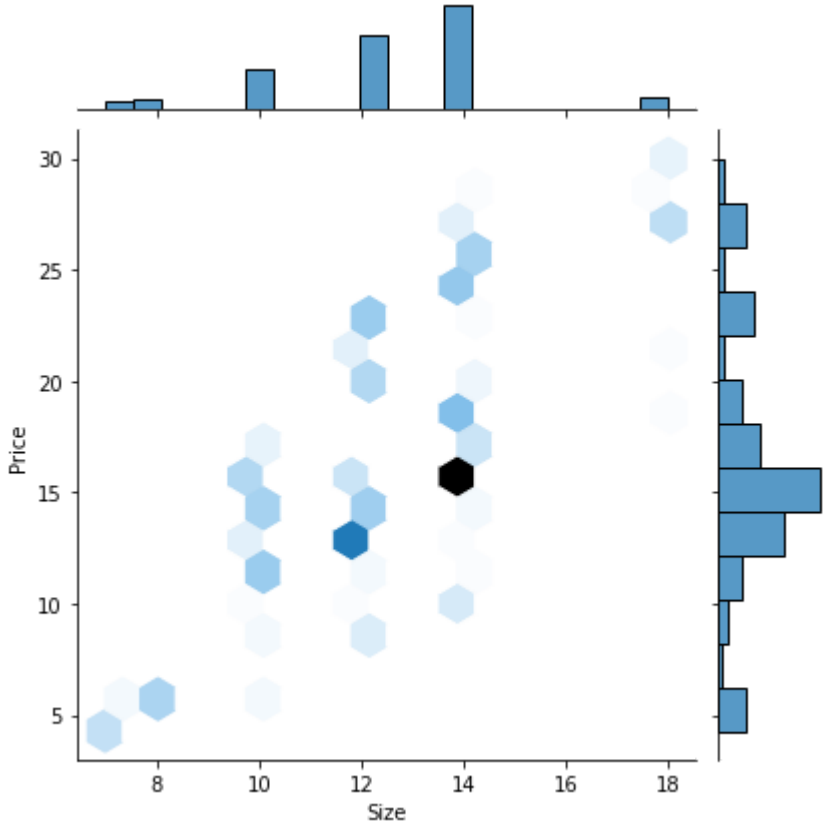

In [16]:
```
#Парные диаграммы
sns.pairplot(df)
```

Out[16]:
```
<seaborn.axisgrid.PairGrid at 0x1ddd91bdc48>
```

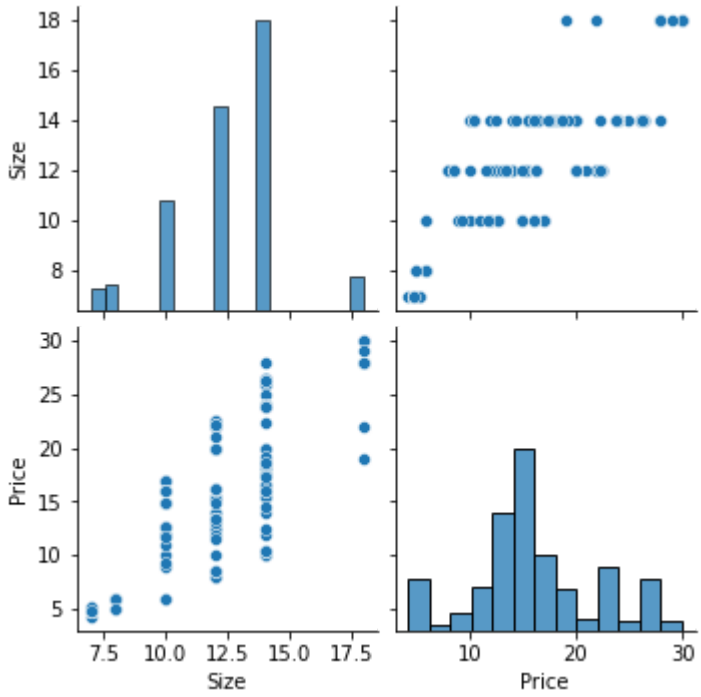

Ящик с усами

In [17]:
```
sns.boxplot(x=df["Price"])
```

Out[17]:
```
<AxesSubplot:xlabel='Price'>
```

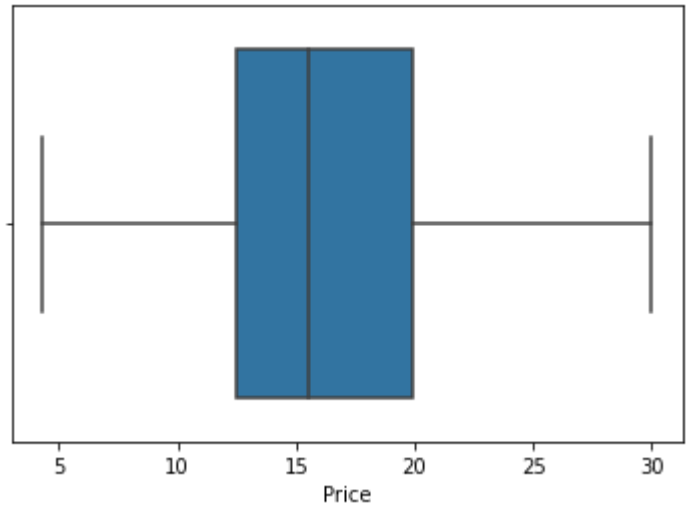

In [18]:
```
sns.boxplot(x="Price", y="Company", data=df)
```

Out[18]:
```
<AxesSubplot:xlabel='Price', ylabel='Company'>
```

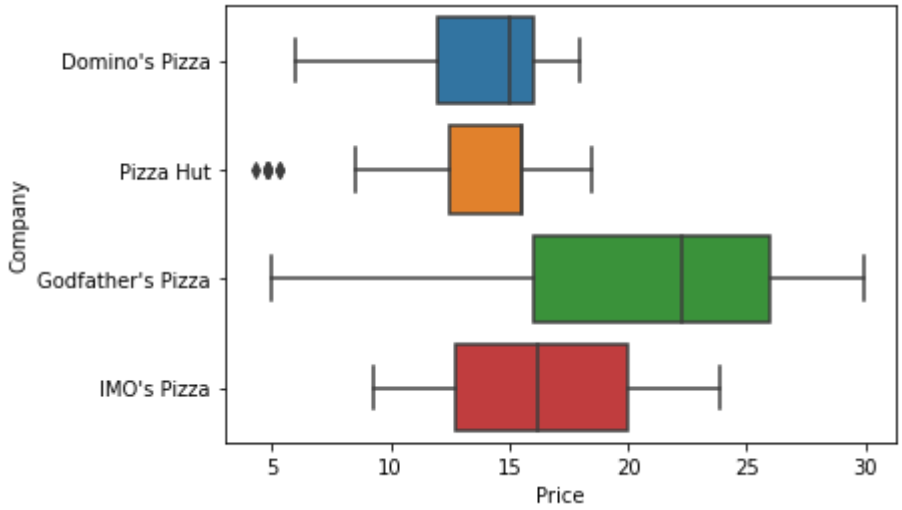

Violin plot

In [19]:
```
sns.violinplot(x=df["Size"])
```

Out[19]:
```
<AxesSubplot:xlabel='Size'>
```

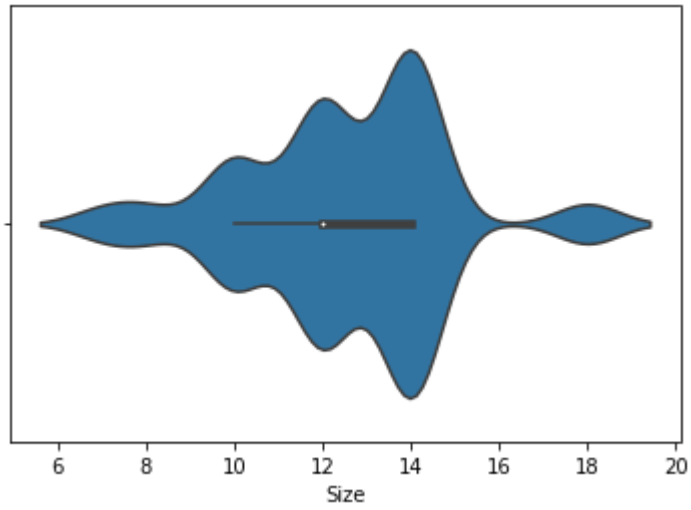

In [20]:
```
sns.violinplot(x="Size", y="Price", data=df)
```

Out[20]:
```
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

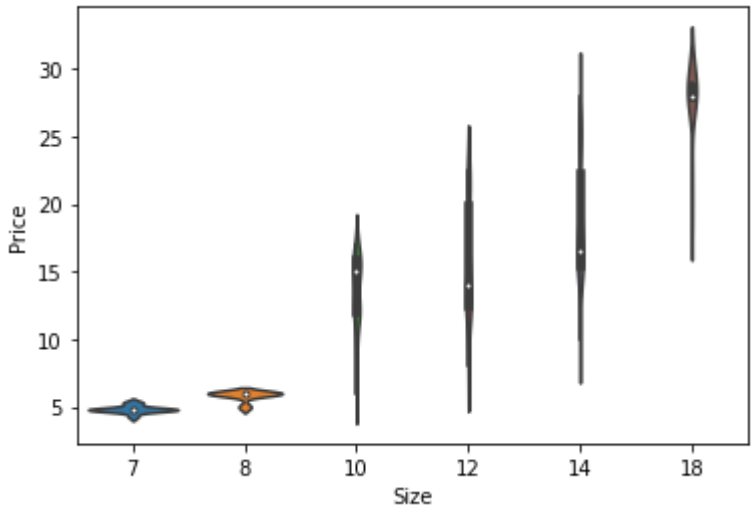

4) Информация о корреляции признаков

In [21]:
```
#Корреляция по критерию Пирсона
df.corr(method="pearson")
```

Out[21]:

	Size	Price
Size	1.000000	0.711833
Price	0.711833	1.000000

In [22]:
```
#Корреляция Кендалла
df.corr(method="kendall")
```

Out[22]:

	Size	Price
Size	1.000000	0.525855
Price	0.525855	1.000000

In [23]:
```
#Корреляция Спирмена
df.corr(method="spearman")
```

Out[23]:

	Size	Price
Size	1.000000	0.633828
Price	0.633828	1.000000

In [24]:
```
#Визуализация корреляционной матрицы
sns.heatmap(df.corr(), annot=True, fmt=".4f", cmap="YlGnBu")
```

Out[24]:
```
<AxesSubplot:>
```

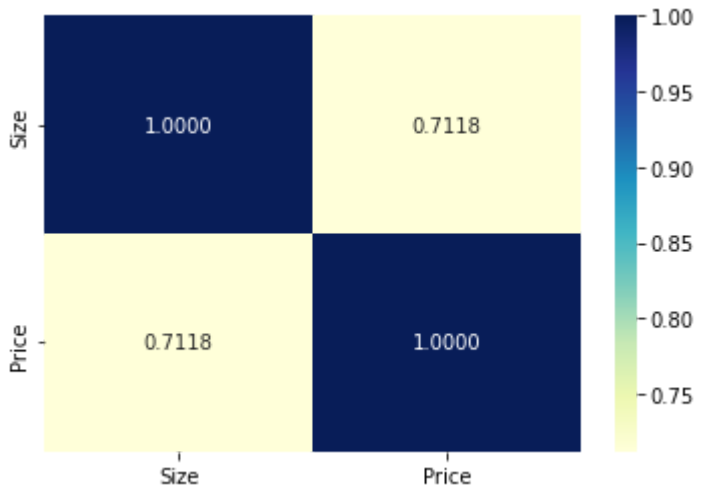

In [25]:
```
fig, ax = plt.subplots(1, 3, sharex="col", sharey="row", figsize=(15,4))
sns.heatmap(df.corr(method="pearson"), ax=ax[0], annot=True, fmt=".4f")
sns.heatmap(df.corr(method="kendall"), ax=ax[1], annot=True, fmt=".4f")
sns.heatmap(df.corr(method="spearman"), ax=ax[2], annot=True, fmt=".4f")
fig.suptitle("Корреляционные матрицы, построенные различными методами")
ax[0].title.set_text("Пирсон")
ax[1].title.set_text("Кендалл")
ax[2].title.set_text("Спирмен")
```

In [ ]: